公东式区

mp.weixin.qq.com

分布式系 统一致性 发展史 (二) 网络模型

about:reader?url=http:...

## 型

分布式系统一致性发...

| 导语:

在本系列第一篇文章中我们提到

about:reader?url=http:...

如何启发人们在 分布式系统中开 始使用新的的思 维方式,并介绍 了Sequential Consistency和 Linearizability. 本

分布式系统一致性发...

about:reader?url=http:...

一致性发展的第 二篇长文,会介 绍他们所延展出 来的一些应用问 题 , 让大家更好 的理解这两种一

致性模型。

分布式系统一致性发...

about:reader?url=http:...

之前,我们先定 义一下分布式系 统中的网络和故 隨的模型. 这部 分稍微有点枯燥, 但很重要. 了解 它们才能继续研

分布式系统一致性发...

究更深层的问题。

分布式系统一致性发... about:reader?url=http:...

分布式系统中的 网络模型 同步网络 (synchronous network)

这里的同步网络

分布式系统一致性发... about:reader?url=http:...

和编程中的同步 阻塞io和异步非 阻塞io是两回事, 不要弄混了。

## 同步网络是指:

i). 所有节点的时

ii). 网络的传输时 间有上限

iii). 所有节点的 计算速度一样.

这意味着整个网

行. 每个round中 任何节点都要执 行完本地计算并 日可以完成一个 仟意大小消息的 传输. 一个发出 的消息如果在一

到达,那么一定 是网络中断造成 的. 这个消息会 丢失. 不会延迟 到第二个round 到达,在现实生 活中这种网络比

同步网络仍然是 在计算机科学中 是不可缺少的一 个模型, 在这种 模型下可以解决 一些问题. 比如 拜占庭式故障.

但我们每天打交

异步网络

分布式系统一致性发... about:reader?url=http:...

道的网络大多都 是异步网络.

(asynchornous network)

和同步网络相反,

无上限. 消息的 传输延迟无上限. 节点计算的速度 不可预料. 这就 是和我们每天打 交道的网络类型. 在异步网络中.

解决, 比如当你 发给一个节点一 个消息之后几秒 钟都没有收到他 的应答. 有可能 这个节点计算非 常慢. 但是也可

者网络延迟造成的, 你很难判断到底是发生了什么样的故障.

Fault, Error and Failure 这不是绕口令.

们的关系. 过去 很多时候这些词 汇混用导致很多 问题,后来统一 了这几个词的定 Ϋ:

Fault: 在系统中

下确的执行叫做 一个fault. 比如内 存写入错误. 但 是如果内存是 ECC的那么这个 fault可以立刻被 修复,就不会导

致error.

分布式系统一致性发... about:reader?url=http:...

Error: 如果一个 fault没能在结果 影响到整个系统 状态之前被修复. 结果导致系统的 状态错误, 那么

比如不带ECC的 内存导致一个计 算结果错误.

Failure: 如果一个系统的error没能在错误状态传

前被修复,换句话说error被扩散出去了,这就是一个failure.

所以他们的关系 是fault导致error,

在分布式系统中. 每个节点很难确 定其它节点内部 的状态. 诵常只 能诵讨和其他节 点的交互监测到 failure. 接下来我

般都是指failure.

分布式系统中的 故障模型 在分布式系统中, 故障可能发生在 节点或者通信链

按照从最广泛最难的到最特定最简单的顺序列出故障类型:

byzantine failures: 这是最

一个节点压根就 不按照程序逻辑 执行. 对它的调 用会返回给你随 意或者混乱的结 果. 要解决拜占 庭式故障需要有

故障节点必须小 干1/3. 诵常只有 某些特定领域才 会考虑这种情况 通过高冗余来消 除故障. 关于拜 占庭式故障你现

最难的情况,稍 后我们会更详细 的介绍它.

crash-recovery failures: 它比 byzantine类故障

那就是节点总是 按照程序逻辑执 行. 结果是正确 的. 但是不保证 消息返回的时间. 原因可能是crash 后重启了. 网络

络中的高延迟. 对于crash的情况 还要分健忘 (amnesia)和非健 忘的两种情况. 对于健忘的情况. 是指这个crash的

完整的保存crash 之前的状态信息, 非健忘是指这个 节点crash之前能 把状态完整的保 存在持久存储上. 启动之后可以再

次按照以削的状态继续执行和通信.

omission
failures: 比
crash-recovery
多了一个限制,

忘. 有些算法要 求必须是非健忘 的. 比如最基本 版本的Paxos要 求节点必须把 ballot numberi근 录到持久存储中.

一旦crash,修复之后必须继续记住之前的ballot number.

crash-stop failures: 也叫做 crash failure或者

它比omission failure多了一个 故障发生后要停 止响应的要求. 比如一个节点出 现故障后立即停 止接受和发送所

络发生了故障无 法进行任何诵信. 并目这些故障不 会恢复. 简单讲, 一旦发生故障, 这个节点 就不会 再和其它节点有

他的名字描述的 那样, crash and stop.

分布式系统中的 故障类型还有其 他的分类方法,

omission去掉. 有 些会加入 performance failures. 有些会 把crash-stop和 fail-stop根据故障 检测能力区分开,

此处介绍的是使

分布式系统一致性发... about:reader?url=http:...

用较为广泛的一种分类方法. 它们的关系如下:

这四种故障中, 拜占庭式故障是

Leslie Lamport 证明在同步网络 下. 有办法验证 消息真伪. 故障 节点不超过1/3的 情况下才有可能 解决. 在现实中.

本非常高. 只有 在非常关键的领 域会考虑使用 BFT(Byzantine Fault Tolerance) 的设计. 比如 NASA的航天飞

抗各种射线影响 的AP-101系列计 **篁机** 其中四台 使用同样的软件 运行. 另外一台 独立运行另外一 个独立编写版本

的软件. 空客

分布式系统一致性发... about:reader?url=http:...

A320有7台计算 机, 分别是三种 硬件上运行的三 套独立编写的软 件. 美国海军的 海狼级核动力攻 击型潜水艇

了多组计算机控 制. 绝大多数应 用是不太考虑重 力加速度和射线 辐射对硬件的影 响的. 稍后本文 会介绍拜占庭将

释一下这类问题. 大多数分布式应 用主要是关注 crash-recovery 的情况. 而crashstop是一种过于 理想化的情况.

后面我们在介绍

分布式系统一致性发... about:reader?url=http:...

Paxos算法的时 候会给大家讲解 为什么这个讨干 理想化的故障模 型会带来什么样 的问题.

## Consensus问题

Consensus问题 是因为 Consensus问题 是分布式系统中 最基础最重要的 问题之一. 也是 应用最为广泛的

的分布式系统的 经典问题比如 self-stabilization 的实际应用要多, 我们可以通过介 绍Consensus问 题来更加深入得

到的 Linearizability和 Sequential Consistency.

Consensus所解 决的最重要的典

理(fault tolerannce). th 如在原子广播 (Atomic Broadcast)和状 态机复制(State Machine

候,我们都要在 某一个步骤中让 一个系统中所有 的节点对一个值 达成一致, 这些 都可以归纳为 Consensus问题.

存在故障, 我们 要忽略掉这些故 整个系统继续正 确运行,这就是 fault tolerance. Consensus问题

异步网络中如何处理容错.

Consensus问题的定义包含了三个方面,一般的Consensus问题

定义为:

分布式系统一致性发... about:reader?url=http:...

termination: 所 有讲程最终会在 有限步数中结束 并选取一个值. 算法不会无尽执 行下去.

有非故障进程必 须同意同一个 值.

validity: 最终达 成一致的值必须

一个,如果所有初始值都是vx,那么最终结果也必须是vx。

Consensus要满 足以下三个方面:

agreement 和 validity. 这三个要 素定义了所有 Consensus问题 的本质. 其中 termination是 liveness的保证.

validity是safety 的保证, 分布式 系统的算法

liveness和safety 就像一对死对头, 关于liveness和

们将会在本系列 后面的文章中介 绍. 所有需要满 足这三要素的问 题都可以看做是 Consensus问题 的变体.

如果是拜占庭式 故障. 那么Paxos 和Raft也无法解 决这一类问题. 严格讲这是没有 办法解决的. 很 长一段时间内我

们只看到在航天

分布式系统一致性发... about:reader?url=http:...

同步网络解决此 类问题. (直到 Babara Liskov在 2002年提出

PBFT我们才可 以在放松

下解决此类问题, 为此Barbara Liskov获得了图 灵奖. 我们可能 会在将来的文章 中介绍PBFT). 对 于一般的应用来

现的概率太低而 解决的成本实在 是太高, 所以我 们—般不考虑拜 占庭式故障. 我 们主要是关注 crash-recovery

的异步网络. 这 种情况下根据 FLP理论, 只要有 一个故障节点. Paxos/Raft都是 有可能讲入无限 循环而无法结束

这个概率非常低, 如果放松 liveness的要求. 我们认为这种情 况下Paxos/Raft 是可以解决的. 以下介绍

的时候我们都不 考虑拜占庭式故 障. 我们的故障 模型是crashrecovery failures, 网络模 型是异步网络.

在同步网络中因 为所有节点时间 偏移有上限, 所 有包的传输延迟 也有上限. 节点 会在一个round 内完成计算并且 传输完成. 所以

间还没有收到返 回的消息, 我们 就可以确定要么 网络中断要么节 点已经crash. 但 是我们现实当中 都是异步网络.

固定上限的, 当 很长时间—个节 点都没有返回消 息的时候. 我们 不知道是这个节 点计算速度太慢. 还是已经crash

节点计算太慢, 超时之后,过了 一会这个节点又 把结果再发回来 了. 这就超出 crash-stop故障 模型的范围了,

crash recovery 的模型来解决. 在异步网络中无 法区分crash和包 延迟会导致 consensus问题 非常难解决。

今天是分布式系 统发展史第二篇 的第一部分内 容,明天我们将 继续发布第二部 分内容《两阶段 提交和三阶段提 交的发展史》 ,

敬请期待。

分布式系统一致性发... about:reader?url=http:...

如果您想投稿给 我们,或者想转 发和采用我们的 稿件,请回复"合 作", 小编会在2 小时内回复您的

投稿和合作需 求。

分布式系统一致性发... about:reader?url=http:...

## 本文作 者:Daniel,吴 强,现任点融网 首席社交平台架

构师, 专注分布 式系统和移动应 用. 有十三年的 开发经验,目前 在点融做最爱的 两件事情: 写代 码和重构代码。

资,点融网开始 了大规模的扩 张,需要各种优 秀人才的加入, 如果您觉得自己 够优秀,欢迎加 入我们!

第75页 共75页 2016/6/21 17:42

分布式系统一致性发... about:reader?url=http:...